

Лабораторна робота №1.

Робота з DICOM/NIfTI та попередня обробка медичних зображень

Мета

Навчитися читати справжні серії DICOM так, щоб не втратити ні геометрії, ні фізичного змісту пікселів: зібрати тривимірний масив зі зрізів, перевірити цілісність серії, перевести значення КТ в одиниці Гаунсфілда й відобразити їх у вікнах, зберегти серію в NIfTI зі збереженням просторових координат і привести її до ізотропного спейсингу. Друга мета — підготувати дані до навчання моделей без витоку: знайти в заголовках персональні дані та зробити поділ на train, validation і test на рівні пацієнта, вимірювши, скільки витоку дає поділ за знімками.

Склад бригади і розподіл ролей

Роботу виконує бригада з трьох осіб. Кожен учасник відповідає за свою частину, має власний вимірюваний результат і захищає його окремо. Звіт контролю якості бригада складає разом.

- **Учасник А — читання серій і цілісність.** Завантажує серії, збирає їх у тривимірні масиви в правильному порядку, складає таблицю ключових тегів і перевіряє серії на пропуски та нерівномірний крок.
- **Учасник В — інтенсивності й геометрія.** Переводить КТ в одиниці Гаунсфілда, будує зрізи у вікнах, зберігає серії в NIfTI з перевіркою матриці affine, виконує ресемплінг.
- **Учасник С — деідентифікація і поділ даних.** Знаходить у заголовках теги з персональними даними, порівнює їх зі стандартом і будує поділ на рівні пацієнта з вимірюванням витоку.

Теоретичні відомості

Файл DICOM зберігає не лише пікселі, а й набір елементів даних: тег (група, елемент), тип значення (VR), кратність (VM) і саме значення. Файли однієї серії мають спільний SeriesInstanceUID; порядок файлів в архіві нічого не говорить про порядок зрізів у тілі.

Геометрія зрізу задається модулем Image Plane (DICOM PS3.3, C.7.6.2): ImagePositionPatient — координати центру першого пікселя в мм, ImageOrientationPatient — дві одиничні напрямні рядка $\mathbf{X}$ і стовпця $\mathbf{Y}$, PixelSpacing — відстані між центрами сусідніх рядків і стовпців. Нормаль до зрізу $\mathbf{N} = \mathbf{X} \times \mathbf{Y}$; проєкція позиції зрізу на нормаль $d = \mathbf{N} \cdot \mathbf{P}$ дає порядок зрізів і крок між ними. SliceThickness — номінальна товщина реконструкції, а не крок.

Центр вокселя (i, j, k) (стовпець, рядок, зріз) у системі координат пацієнта LPS:

$$\mathbf{P}(i, j, k) = \mathbf{P}_0 + i \Delta_c \mathbf{X} + j \Delta_r \mathbf{Y} + k \Delta_s \mathbf{N}, \quad (1)$$

де $\mathbf{P}_0$ — позиція першого зрізу, Δ_c і Δ_r — відстані між стовпцями і рядками, Δ_s — крок між зрізами. Ця сама залежність, записана матрицею 4×4 , — матриця affine. NIfTI за угодою зберігає її в системі RAS, яка відрізняється від LPS знаком перших двох осей.

Одиниці Гаунсфілда (HU, також пишуть «Хаунсфілд») визначені через лінійні коефіцієнти ослаблення: $HU = 1000 (\mu - \mu_{\text{вода}}) / (\mu_{\text{вода}} - \mu_{\text{повітря}})$. Файл зберігає не HU, а цілі значення SV ; перерахунок задає Modality LUT (PS3.3, C.11.1): $HU = \text{RescaleSlope} \cdot SV + \text{RescaleIntercept}$. **Вікно відображення** (VOI LUT, PS3.3, C.11.2) з центром c і шириною w лінійно відображає інтервал $[c - w/2, c + w/2]$ на діапазон яскравості; усе нижче — чорне, вище — біле. Тег `WindowCenter` може містити кілька значень.

Деідентифікація за PS3.15, додаток E, визначає для кожного тегу дію: видалити, замінити порожнім або фіктивним значенням, замінити UID узгоджено. Персональні дані можуть лишатися і в пікселях (впечатаний текст).

Поділ на рівні пацієнта. Знімки одного пацієнта схожі між собою більше, ніж знімки різних людей. Якщо вони потрапляють і в `train`, і в `test`, модель частково «впізнає» пацієнта, і тестова оцінка стає завищеною — це витік даних (data leakage).

Корисні посилання для ознайомлення:

- [DICOM PS3.3, C.7.6.2 Image Plane Module](#) — позиція, орієнтація і спейсинг;
- [DICOM PS3.3, C.11.1 Modality LUT](#) і [C.11.2 VOI LUT](#) — перерахунок у HU і вікна;
- [DICOM PS3.15, додаток E](#) — профілі конфіденційності атрибутів;
- [NiBabel: Coordinate systems and affines](#) — системи координат і матриця `affine`;
- [Документація pydicom](#) — читання файлів і тегів;
- [TCIA NBIA REST API](#) — завантаження серій без облікового запису.

Середовище

Python 3.12 і пакети з файлу `requirements-students.txt` курсу (версії закріплені); обчислення — лише на CPU. Уся робота розрахована на ноутбук, що виконується командою *Restart & Run All* **не довше 10 хвилин**; обсяг даних — близько 80 МБ. Дані завантажуються без облікового запису:

- серія KT LIDC-IDRI-0001 (колекція LIDC-IDRI, TCIA, CC BY 3.0):
<https://services.cancerimagingarchive.net/nbia-api/services/v1/getImage?SeriesInstanceUID=1.3.6.1.4.1.14519.5.2.1.6279.6001.179049373636438705059720603192>
- серія MPT Prostate3T-01-0019 (колекція Prostate-3T, TCIA, CC BY 3.0):
<https://services.cancerimagingarchive.net/nbia-api/services/v1/getImage?SeriesInstanceUID=1.3.6.1.4.1.14519.5.2.1.7308.2101.254832349148503364909115228931>
- метадані NIH ChestX-ray14 (`Data_Entry_2017_v2020.csv`, без знімків):
<https://nihcc.app.box.com/v/ChestXray-NIHCC>

Порядок виконання

1. [A] Завантажте серію KT LIDC-IDRI-0001 і серію MPT Prostate3T-01-0019. Зберіть кожну в тривимірний масив, упорядкувавши зрізи за `ImagePositionPatient`. Наведіть таблицю ключових тегів обох серій: модальність, розмір пікселя, товщина зрізу, фактичний крок між зрізами, орієнтація, параметри перерахунку інтенсивностей, вікно.
2. [A] Перевірте цілісність обох серій: пропущені зрізи, нерівномірний крок, розбіжність між `SliceThickness` і фактичною відстанню між зрізами. Опишіть знайдене.

3. **[В]** Переведіть КТ в одиниці Гаунсфілда. Покажіть аксіальний, корональний і сагітальний перерізи у трьох вікнах, з підписаними межами кожного вікна і посиланням на джерело, звідки взято його параметри.
4. **[В]** Збережіть обидві серії у NIfTI. Доведіть, що матриця *affine* правильно передає орієнтацію і спейсинг: для однієї анатомічної точки наведіть її координати у вокселях і міліметрах до і після конвертації.
5. **[В]** Приведіть КТ до ізотропного спейсингу 1 мм двома способами інтерполяції. Порівняйте розмір масиву, займану пам'ять і час.
6. **[С]** Складіть перелік тегів однієї серії, що можуть ідентифікувати пацієнта. Для кожного вкажіть, що з ним зроблено в опублікованих даних, і порівняйте з дією, яку передбачає PS3.15, додаток E.
7. **[С]** На метаданих NIH ChestX-ray14 зробіть два поділи 70/15/15: за знімками і за пацієнтами. Для кожного поділу виміряйте, яка частка тестових знімків належить пацієнтам, що є в *train*, і скільки таких пацієнтів.
8. **[разом]** Складіть звіт контролю якості: таблиця знахідок, 3–5 рисунків, висновок про придатність серій до подальшої обробки. Перша комірка ноутбука — хто з учасників за які комірки відповідав; ноутбук виконується від початку до кінця без ручних правок.

Контрольні запитання

1. Чому порядок файлів в архіві серії не можна використовувати як порядок зрізів? Як правильно визначити порядок і крок?
2. Чим *SliceThickness* відрізняється від кроку між зрізами? Коли вони не збігаються?
3. Як із тегів *RescaleSlope* і *RescaleIntercept* отримати HU? Що робити, якщо цих тегів у серії немає?
4. Що задають центр і ширина вікна? Чому для легень і для середостіння використовують різні вікна?
5. Як записати координати вокселя в міліметрах через *ImagePositionPatient*, *ImageOrientationPatient* і *PixelSpacing*? Чим системи LPS і RAS відрізняються?
6. Які теги DICOM можуть ідентифікувати пацієнта, крім імені? Чому UID також потребують заміни?
7. Чому поділ за знімками завищує оцінку моделі? Від чого залежить величина цього завищення?

Література

- [1] NEMA. Digital Imaging and Communications in Medicine (DICOM) Standard, PS3.3 і PS3.15. <https://www.dicomstandard.org/current>.
- [2] Armato S. G. et al. The Lung Image Database Consortium (LIDC) and Image Database Resource Initiative (IDRI): A completed reference database of lung nodules on CT scans. *Medical Physics*, 2011, 38(2), 915–931. doi:10.1118/1.3528204.
- [3] Armato S. G. et al. Data From LIDC-IDRI. The Cancer Imaging Archive, 2015. doi:10.7937/K9/TCIA.2015.L09QL9SX. Умови використання: CC BY 3.0, з посиланням на [2]–[4].

- [4] Clark K. et al. The Cancer Imaging Archive (TCIA): Maintaining and Operating a Public Information Repository. *Journal of Digital Imaging*, 2013, 26(6), 1045–1057. [doi:10.1007/s10278-013-9622-7](https://doi.org/10.1007/s10278-013-9622-7).
- [5] Data From Prostate-3T. The Cancer Imaging Archive, 2015. [doi:10.7937/K9/TCIA.2015.QJTV5IL5](https://doi.org/10.7937/K9/TCIA.2015.QJTV5IL5). Умови використання: CC BY 3.0.
- [6] Wang X. et al. ChestX-ray8: Hospital-Scale Chest X-Ray Database and Benchmarks on Weakly-Supervised Classification and Localization of Common Thorax Diseases. *CVPR*, 2017. [doi:10.1109/CVPR.2017.369](https://doi.org/10.1109/CVPR.2017.369). Умови використання набору: вільне використання з посиланням на цю статтю й NIH Clinical Center.
- [7] Brett M. et al. NiBabel: Coordinate systems and affines. https://nipy.org/nibabel/coordinate_systems.html.