

Лабораторна робота №2.

Класифікація медичних зображень із використанням CNN та transfer learning

5 жовтня 2026 р.

Мета

Навчитися переносити попередньо навчену згорткову мережу на скринінг туберкульозу за рентгенограмою грудної клітки в межах бюджету процесора і чесно оцінювати результат: поділ на рівні пацієнта, вибір епохи, порогу й температури лише на validation, середнє і розкид за кількома зернами, калібрування ймовірностей, окрема оцінка для кожного джерела знімків. Друга мета — виміряти, що дає попереднє навчання на рентгенограмах порівняно з ImageNet і що дає розморожування останнього блоку порівняно з навчанням лише класифікаційної голови, коли архітектура мережі однакова.

Склад бригади і розподіл ролей

Роботу виконує бригада з трьох осіб. Кожен учасник відповідає за свою частину, має власний вимірюваний результат і захищає його окремо. Порівняння за джерелами і розбір помилок бригада робить разом.

- **Учасник А — дані й поділ.** Завантажує набори, будує копії 256 px, складає таблицю метаданих, знаходить знімки одного пацієнта, робить поділ 70/15/15 і доводить, що частини не перетинаються.
- **Учасник В — моделі.** Обчислює ознаки обох попередньо навчених мереж, будує базову модель, навчає чотири варіанти донавчання по 5 зерен і веде журнал прогонів (обрана епоха, час, валідаційна AUC).
- **Учасник С — оцінка й калібрування.** Задає правило вибору порогу, рахує метрики на test для кожного прогону, будує діаграму надійності й підбирає температуру.

Теоретичні відомості

Перенесення навчання (transfer learning) бере мережу, навчену на великому наборі, як відправну точку для малої задачі: 800 рентгенограм замало, щоб навчити глибоку мережу з нуля. Режими різняться тим, які шари навчаються. *Заморожений екстрактор ознак* (frozen feature extractor): знімок один раз проходить мережу, вектор ознак після глобального усереднення (global average pooling, GAP) подають у лінійний класифікатор, наприклад логістичну регресію. *Навчання лише голови* (head-only): мережа заморожена, а новий вихідний шар навчається градієнтним спуском з ранньою зупинкою. *Часткове донавчання* (partial fine-tuning): разом із головою навчаються останні блоки мережі, нижні лишаються такими, як після попереднього навчання. Повне донавчання DenseNet-121 на процесорі в бюджет роботи не вкладається. Заморожена частина мережі на кожній

епосі дає той самий вихід для того самого знімка, тож, якщо вхід не змінюється аугментаціями, цей вихід досить обчислити один раз і далі навчати лише розморожену частину.

DenseNet-121 (Huang et al., 2017) складається з чотирьох щільних блоків (dense blocks): кожен шар блоку отримує на вхід карти ознак усіх попередніх шарів цього блоку. Між блоками стоять перехідні шари (transition) зі згорткою 1×1 і усередненням 2×2 . Після останнього блоку denseblock4 — пакетна нормалізація norm5, ReLU і глобальне усереднення, що дає 1024 ознаки знімка. У цій роботі «останній блок» — це denseblock4 разом із norm5. **Пакетна нормалізація** (batch normalization) у заморожених шарах має працювати в режимі оцінювання: інакше її ковні статистику підлаштується під кілька сотень рентгенограм, і вхід розмороженої частини зміниться, хоча ваги заморожено.

Два варіанти попереднього навчання однієї архітектури. Ваги ImageNet із torchvision очікують три канали, нормовані за каналами середнім (0,485; 0,456; 0,406) і стандартним відхиленням (0,229; 0,224; 0,225) після ділення на 255; сірий канал рентгенограми повторюють тричі. Ваги densenet121-res224-all бібліотеки TorchXRayVision (Cohen et al., 2022) навчено на семи відкритих наборах рентгенограм грудної клітки на 18 знахідок, туберкульозу серед яких немає. Вони очікують один канал у діапазоні $[-1024; 1024]$: для 8-бітного знімка $x' = (2x/255 - 1) \cdot 1024$. Помилкова шкала входу не дає жодної помилки виконання, лише гіршу якість. Обидві мережі попередньо навчено на вході 224 px; менший вхід дешевший на процесорі, але змінює масштаб ознак.

Validation i test. Частина validation потрібна для всіх виборів: епохи (рання зупинка, early stopping), сили регуляризації, порогу, температури. Частина test відкривається один раз для остаточної оцінки; будь-який вибір за нею завищує оцінку. Знімки одного пацієнта мають бути в одній частині. У наборах Montgomery і Shenzhen ім'я файлу ідентифікує знімок, а не пацієнта: про повторні знімки того самого пацієнта свідчать клінічні записи (ClinicalReadings).

Метрики. При порозі t знімок з оцінкою $p \geq t$ вважається позитивним; TP, FP, TN, FN — кількості істинно- і хибнопозитивних, істинно- і хибнонегативних. Чутливість $Se = TP/(TP + FN)$, специфічність $Sp = TN/(TN + FP)$, влучність (precision) $P = TP/(TP + FP)$, $F_1 = 2 P Se/(P + Se)$. Матриця помилок (confusion matrix) — таблиця 2×2 цих кількостей. ROC-AUC — площа під кривою Se проти $1 - Sp$ за всіма порогоми, тобто ймовірність того, що випадковий знімок із туберкульозом отримає вищу оцінку, ніж випадковий знімок без нього. PR-AUC (середня влучність, average precision) — площа під кривою «влучність — повнота», де повнота (recall) — те саме, що чутливість; її рівень для випадкової моделі дорівнює частці хворих у вибірці. Правило вибору порогу (наприклад, максимум індексу Юдена $J = Se + Sp - 1$ або задана чутливість) фіксують до того, як дивляться на test.

Калібрування (calibration): модель калібрована, якщо серед знімків з оцінкою близько p частка хворих теж близько p . *Діаграма надійності* (reliability diagram) ділить оцінки на M кошиків рівної ширини $B_1, \dots, B_M$ і для кожного порівнює середню оцінку $\text{conf}(B_m)$ з часткою хворих $\text{acc}(B_m)$. Очікувана похибка калібрування

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{n} |\text{acc}(B_m) - \text{conf}(B_m)|, \quad (1)$$

де n — кількість знімків. *Температурне масштабування* (temperature scaling; Guo et al., 2017) ділить логіт z на число $T > 0$: $p = \sigma(z/T)$, де σ — сигмоїда; T підбирають мінімізацією негативної логарифмічної правдоподібності на validation. Перетворення монотонне, тому ROC-AUC і PR-AUC воно не змінює.

Розкид за зернами. Зерно генератора випадкових чисел (seed) задає ініціалізацію голови, порядок батчів і аугментації. Один прогін не дозволяє порівнювати варіанти: різниця середніх має бути більшою за розкид між зернами одного варіанта.

Особливості наборів. Мітка — останній символ імені файлу (_0 — норма, _1 — туберкульоз). Знімки Montgomery — 8-бітні сірі PNG близько 4000×4900 px; знімки Shenzhen — PNG з палітрою або RGB, які треба читати з перетворенням у сірий (`Image.convert("L")`), інакше частина з них

виявиться негативом. Частка туберкульозу і формат кадру в двох лікарнях різні, тож модель може навчитися впізнавати джерело замість хвороби.

Корисні посилання для ознайомлення:

- [torchvision: densenet121](#) — ваги ImageNet, препроцесинг входу;
- [TorchXRayVision: код і опис ваг](#) — моделі, навчені на рентгенограмах, і нормалізація входу;
- [PyTorch: Transfer Learning for Computer Vision Tutorial](#) — заморожування шарів і донавчання;
- [CS231n: Transfer Learning](#) — коли заморожувати, коли донавчати;
- [scikit-learn: Metrics and scoring](#) — ROC-AUC, середня влучність, матриця помилок;
- [scikit-learn: Probability calibration](#) — криві калібрування;
- [Guo et al. On Calibration of Modern Neural Networks](#) — ECE і температурне масштабування (§2, §4.2).

Середовище

Python 3.12; усі пакети з версіями — у `requirements-students.txt` на сторінці лабораторних (<https://imd-course-kpi.vercel.app/labs/requirements-students.txt>; версії закріплені, зокрема torch 2.10.0, torchvision 0.25.0, torchxrayvision 1.4.0); обчислення — лише на CPU. Ноутбук виконується командою *Restart & Run All* **не довше 2 годин**. Верхні межі окремих етапів:

- заморожена частина мережі (до останнього щільного блоку, вхід 224 px) для 800 знімків — не довше 4 хв на кожен варіант попереднього навчання;
- базова модель і навчання лише голови — секунди на прогін;
- одне донавчання останнього блоку (до 6 епох) — не довше 2 хв; таких прогонів 10, разом не довше 20 хв;
- оцінка, калібрування й розбір помилок — не довше 10 хв.

Межі — це час еталонного розв’язку на Apple M1 Max (8 потоків, жовтень 2026), помножений на 2,5: на типовому ноутбуці процесор у 2–3 рази повільніший. Межі розраховано для входу 224 px, коли вихід замороженої частини обчислено один раз; донавчання з аугментаціями, що змінюють вхід на кожній епосі, у ці межі вкладається лише на меншому вході. Якщо прогін не вкладається, зменшують розмір входу чи кількість епох, а не кількість зерен.

Дані завантажуються без облікового запису:

- набори Montgomery (138 знімків: 80 норм і 58 із туберкульозом) і Shenzhen (662 знімки: 326 і 336), сторінка наборів — <https://data.lhncbc.nlm.nih.gov/public/Tuberculosis-Chest-X-ray-Datasets/index.html>. Адреси тек без `index.html` віддають помилку 403, тож файли завантажують поштучно за прямими адресами, наприклад https://data.lhncbc.nlm.nih.gov/public/Tuberculosis-Chest-X-ray-Datasets/Montgomery-County-CXR-Set/MontgomerySet/CXR_png/MCUCXR_0001_0.png і https://data.lhncbc.nlm.nih.gov/public/Tuberculosis-Chest-X-ray-Datasets/Shenzhen-Hospital-CXR-Set/CXR_png/CHNCXR_0001_0.png; переліки імен — у файлах `index.html` тек `CXR_png`, клінічні записи — однойменні `.txt` у теках `ClinicalReadings` поруч. 800 знімків займають 4,38 ГБ; поштучно — від 4 до 18 хв залежно від навантаження сервера (заміри 04–05.10.2026). Ti самі набори є архівами <https://openi.nlm.nih.gov/imgs/collections/NLM-MontgomeryCXRSets.zip> (617 МБ) і https://openi.nlm.nih.gov/imgs/collections/ChinaSet_AllFiles.zip (3,77 ГБ), але цей сервер віддає 0,5–0,75 МБ/с: Montgomery — 14–20 хв, Shenzhen — 1,5–2 год;

- копії зі стороною 256 px будує скрипт курсу https://imd-course-kpi.vercel.app/labs/make_cxr256.py: знімки кладуть у теки ПАПКА/data/nlm/Montgomery/CXR_png і ПАПКА/data/nlm/Shenzhen/CXR_png і запускають `python make_cxr256.py --root ПАПКА`; копії з'являються в ПАПКА/data/nlm/cxr256/ разом із таблицею розмірів `sizes.csv`. 800 копій займають 24 МБ і будуються менш ніж за хвилину (замір — 8 с у 8 процессах); після цього оригінали для роботи не потрібні;
- ваги DenseNet-121 ImageNet (32,3 МБ, <https://download.pytorch.org/models/densenet121-a639ec97.pth>) і TorchXRayVision `densenet121-res224-all` (28,4 МБ, GitHub-реліз бібліотеки) завантажуються автоматично при першому створенні моделі;
- для налагодження конвеєра на малих даних можна спершу взяти PneumoniaMNIST з набору MedMNIST (4,2 МБ, знімки 28×28 px, CC BY 4.0; пакет `medmnist` є в `requirements-students.txt`) — необов'язково.

Порядок виконання

1. **[A]** Завантажте набори Montgomery і Shenzhen, зменшіть знімки до 256 px скриптом курсу і складіть таблицю метаданих: файл, джерело, клас, ідентифікатор пацієнта, розмір оригіналу. Поділіть знімки 70/15/15 на рівні пацієнта зі стратифікацією за джерелом і класом (зерно фіксоване) і наведіть кількості знімків і пацієнтів у кожній частині та перевірку, що спільних пацієнтів між частинами немає.
2. **[B]** Побудуйте базову модель — логістичну регресію на ознаках DenseNet-121 без донавчання, окремо для ваг ImageNet і TorchXRayVision; силу регуляризації виберіть на validation.
3. **[B]** Доновчіть DenseNet-121 двома способами — лише класифікаційна голова і останній щільний блок разом із головою — для обох варіантів попереднього навчання. Кожен із чотирьох варіантів — 5 зерен; для кожного прогону запишіть обрану на validation епоху, валідаційну AUC і час.
4. **[C]** Для кожного прогону виберіть поріг на validation за правилом, заданим до перегляду test. На test наведіть ROC-AUC, PR-AUC, чутливість, специфічність, F_1 і матрицю помилок кожного з чотирьох варіантів і базової моделі: середнє і стандартне відхилення за зернами.
5. **[C]** Побудуйте діаграму надійності на test для найкращого за validation варіанта і порахуйте ECE до і після температурного масштабування для всіх прогонів; температуру підберіть на validation.
6. **[разом]** Порівняйте метрики найкращого варіанта окремо на тестових знімках Montgomery і Shenzhen і поясніть розбіжність з урахуванням кількості знімків кожного класу в цих підгрупах.
7. **[разом]** Покажіть 10 найгірших помилок найкращого варіанта (найупевненіші хибні рішення на test) з гіпотезою причини кожної. Перша комірка ноутбука — хто з учасників за які комірки відповідав; ноутбук виконується від початку до кінця без ручних правок.

Контрольні запитання

1. Чому поділ роблять за пацієнтами, а не за знімками? Як у наборах Montgomery і Shenzhen встановити, що два знімки належать одному пацієнтові?
2. Чим відрізняються заморожений екстрактор з логістичною регресією, навчання лише голови і донавчання останнього блоку? Що з них дає найбільший розкид за зернами і чому?

3. Навіщо заморожені шари пакетної нормалізації переводять у режим оцінювання?
4. Чому епоху, поріг і температуру вибирають на validation? Що станеться з оцінкою на test, якщо вибирати за нею?
5. Що вимірюють ROC-AUC і PR-AUC? Чому рівень PR-AUC випадкової моделі залежить від частки хворих?
6. Що таке ECE і від чого залежить її значення, крім самої моделі? Чому температурне масштабування не змінює ROC-AUC?
7. Що, крім попереднього навчання, однакове і що різне у двох порівнюваних моделях? Які висновки можна зробити з різниці їхніх метрик, якщо вона менша за розкид за зернами?
8. Чому метрики окремо на тестових знімках Montgomery ненадійні? Яку довжину матиме 95-відсотковий довірчий інтервал чутливості, якщо хворих у підгрупі близько десяти?

Література

- [1] Jaeger S. et al. Two public chest X-ray datasets for computer-aided screening of pulmonary diseases. *Quantitative Imaging in Medicine and Surgery*, 2014, 4(6), 475–477. doi: [10.3978/j.issn.2223-4292.2014.11.20](https://doi.org/10.3978/j.issn.2223-4292.2014.11.20). Умови використання наборів Montgomery і Shenzhen: посилання на цю статтю й U.S. National Library of Medicine; набори не поширюються за межі навчальної групи, похідні копії не публікуються.
- [2] Huang G., Liu Z., van der Maaten L., Weinberger K. Q. Densely Connected Convolutional Networks. *CVPR*, 2017. doi: [10.1109/CVPR.2017.243](https://doi.org/10.1109/CVPR.2017.243).
- [3] Cohen J. P. et al. TorchXRyVision: A library of chest X-ray datasets and models. *MIDL*, PMLR 172, 2022. <https://proceedings.mlr.press/v172/cohen22a.html>. Ліцензія коду — Apache-2.0.
- [4] Deng J. et al. ImageNet: A large-scale hierarchical image database. *CVPR*, 2009. doi: [10.1109/CVPR.2009.5206848](https://doi.org/10.1109/CVPR.2009.5206848).
- [5] Guo C., Pleiss G., Sun Y., Weinberger K. Q. On Calibration of Modern Neural Networks. *ICML*, PMLR 70, 2017. <https://proceedings.mlr.press/v70/guo17a.html>.
- [6] Raghu M., Zhang C., Kleinberg J., Bengio S. Transfusion: Understanding Transfer Learning for Medical Imaging. *NeurIPS*, 2019. <https://arxiv.org/abs/1902.07208>.
- [7] Yang J. et al. MedMNIST v2 — A large-scale lightweight benchmark for 2D and 3D biomedical image classification. *Scientific Data*, 2023, 10, 41. doi: [10.1038/s41597-022-01721-8](https://doi.org/10.1038/s41597-022-01721-8). Умови використання PneumoniaMNIST: CC BY 4.0.