

Лабораторна робота №3.

Детекція патологічних об'єктів та локалізація діагностичних ознак

5 жовтня 2026 р.

Мета

Навчитися перевіряти, чи вказує класифікатор туберкульозу на місце ураження, а не лише правильно відповідає «так чи ні»: побудувати теплові карти двома методами, перетворити їх на рамки й оцінити на рамках консенсусу рентгенологів метриками рівня об'єкта — IoU, грою у вказування, влучністю й повнотою, кривою FROC. Друга мета — навчитися відрізняти справжню локалізацію від опорних ліній, що нічого не знають про конкретний знімок, і розбирати хибнопозитивні знахідки; у додатковому треку — порівняти слабку локалізацію з детектором, навченим на рамках.

Склад бригади і розподіл ролей

Роботу виконує бригада з трьох осіб. Кожен учасник відповідає за свою частину, має власний вимірюваний результат і захищає його окремо. Порівняння методів бригада робить разом; додатковий трек виконує будь-хто з учасників або всі разом.

- **Учасник А — класифікатор і теплові карти.** Робить поділ за протоколом нижче, навчає класифікатор з 5 зернами, будує теплові карти двома методами для всіх відкладених знімків.
- **Учасник В — рамки й метрики.** Перераховує рамки еталону в координати копій, перетворює карти на рамки, рахує метрики рівня об'єкта і криву FROC для обох методів і апіорної карти.
- **Учасник С — аналіз хибнопозитивних.** Відбирає хибнопозитивні рамки, класифікує їх за анатомічною локалізацією і ймовірною причиною, рахує, яка частка з них лежить поза легенями і як вони розподілені між джерелами.

Протокол поділу даних

Протокол цієї роботи власний; його треба виконати точно.

- Усі знімки, що мають рамки консенсусу (123 знімки, на кожному щонайменше одна невідроджена рамка), відкладаються і використовуються **лише для оцінки локалізації**. Ні їхні пікселі, ні їхні мітки класу не беруть участі в навчанні класифікатора, виборі гіперпараметрів чи порогу.
- Класифікатор навчається на решті 677 знімків: поділ train/validation 85/15 на рівні пацієнта зі стратифікацією за джерелом і класом, зерно поділу фіксоване. Validation служить для ранньої зупинки й вибору гіперпараметрів.

- Окремий test для класифікації не потрібен: класифікаційні метрики в цій роботі — лише контроль того, що модель навчилася.

Причина такого протоколу: при звичайному поділі 70/15/15 у test потрапило б близько 18 знімків із рамками, і висновки про локалізацію на них були б ненадійні.

Теоретичні відомості

Слабка локалізація (weakly supervised localization): класифікатор навчено лише на мітках знімків, рамок він не бачив, але його згорткові шари зберігають просторову структуру, і з них можна прочитати, які ділянки штовхають рішення до класу «туберкульоз».

Карта активації класу (class activation map, CAM; Zhou et al., 2016). Нехай $f_k(x, y)$ — значення каналу k останньої карти ознак у клітинці (x, y) , Z — кількість клітинок. Якщо після неї стоять глобальне усереднення і лінійна голова з вагами w_k і зсувом b , логіт $s = \frac{1}{Z} \sum_{x,y} M(x, y)$, де

$$M(x, y) = \sum_k w_k f_k(x, y) + b. \quad (1)$$

Карта M точно розкладає логіт по клітинках. **Grad-CAM** (Selvaraju et al., 2017) узагальнює це на будь-який шар A і будь-яку голову: $\alpha_k = \frac{1}{Z} \sum_{x,y} \partial s / \partial A_k(x, y)$, $M = \text{ReLU}(\sum_k \alpha_k A_k)$. Методи іншого принципу не використовують градієнтів: *оклюзія* (Zeiler, Fergus, 2014) вимірює, наскільки падає оцінка класу, коли ділянку знімка закривають сірим. **Роздільність карти** задається архітектурою, входом і шаром: у DenseNet-121 на вході 224 px вихід останнього щільного блоку має 7×7 клітинок по 32 px; виходи ранніших блоків мають більшу роздільність, але їхні ознаки менш специфічні до класу.

Від карти до рамок (Wang et al., 2017): карту збільшують до розміру знімка, нормують за мінімумом і максимумом до $[0, 1]$, беруть ділянки вище порогу θ , об'єднують у зв'язні компоненти і обводять кожною рамкою; оцінка рамки — максимум карти в ній.

IoU і зіставлення. Перетин над об'єднанням $\text{IoU}(A, B) = |A \cap B| / |A \cup B|$. Передбачені рамки сортують за спаданням оцінки; кожна стає істиннопозитивною (TP), якщо її IoU з ще не зайнятою рамкою еталону того самого знімка не менший за поріг τ , і тоді ця рамка еталону зайнята; інакше — хибнопозитивною (FP). Незайняті рамки еталону — пропущені (FN). Влучність на рівні об'єктів $P = \text{TP} / (\text{TP} + \text{FP})$, повнота $R = \text{TP} / (\text{TP} + \text{FN})$. Поріг $\tau = 0,5$ прийшов із PASCAL VOC (Everingham et al., 2010); для розмитих вогнищ на рентгенограмах беруть і м'якші пороги.

Гра у вказування (pointing game; Zhang et al., 2018): знімок зараховано, якщо точка максимуму карти лежить у рамці еталону, розширеній на допуск (автори брали 15 px на знімку зі стороною 224 px). Метрика не вимагає меж, лише правильного місця.

FROC (free-response receiver operating characteristic): частка знайдених рамок еталону проти середньої кількості хибнопозитивних рамок на знімок при зміні порогу. На відміну від ROC, знімок може мати кілька уражень і кілька позначок, а позначка зараховується лише в правильному місці.

Опорні лінії. Ураження туберкульозу частіше лежать у верхніх частках легень, тому метод, що завжди вказує туди, влучатиме часто, нічого не знаючи про знімок. *Апріорна карта* (prior map) для знімка i — щільність рамок еталону на інших знімках: скільки їхніх рамок накриває цей піксель. Щоб власні рамки знімка не лишали в карті «дірок», щільність рахують за знімками другої половини (усереднюючи кілька випадкових поділів навпіл), а щоб поріг не дробив сходинки суми прямокутників на острівці, карту згладжують гаусовим фільтром. Карта класифікатора, що не обганяє апріорну, не локалізує ураження конкретного знімка.

Рамки консенсусу NLM. Файли `montgomery_consensus_roi.csv` і `shenzhen_consensus_roi.csv`: по рядку на рамку, колонки `patientId` (ім'я файлу), `x_dis`, `y_dis`, `width_dis`, `height_dis` — лівий верхній кут, ширина й висота в «екранних» пікселях. Екран розмітки мав ширину 1024 px (для Montgomery це перевірено за ручними масками легень, для Shenzhen — припущення, узгоджене з даними): координата в пікселях оригіналу дорівнює екранній, помноженій на $W/1024$,

де W — ширина оригіналу; для копії зі стороною 256 px її ще множать на $256/\max(W, H)$ і, якщо копію доповнено нулями до квадрата, зсувають на половину доповнення. Усього 359 рамок на 123 знімках (Montgomery — 109 на 55, Shenzhen — 250 на 68); 7 вироджених рамок зі стороною менше 5 екранних пікселів відкидають, лишається 352. Рамки є не на всіх знімках з туберкульозом, тому знімок з туберкульозом без рамок не означає «ураження ніде немає».

Детектор (додатковий трек) учить на рамках прямо. YOLOv8 (бібліотека ultralytics) — одно-етапний безякірний детектор: у кожній точці трьох рівнів карт ознак передбачає відстані до сторін рамки й імовірність класу; перекриті рамки прибирає пригнічення немаксимумів (non-maximum suppression, NMS).

Корисні посилання для ознайомлення:

- [Zhou et al. Learning Deep Features for Discriminative Localization](#) — CAM (§2, Figure 2);
- [Selvaraju et al. Grad-CAM](#) — §3;
- [Документація пакета grad-cam](#) — Grad-CAM та інші методи карт для PyTorch;
- [COCO Detection Evaluation](#) — зіставлення, AP, пороги IoU;
- [Ultralytics: режим Train і формат розмітки для детекції](#) — додатковий трек;
- [Сторінка наборів NLM](#) — знімки, клінічні записи й файли рамок консенсусу.

Середовище

Python 3.12; усі пакети з версіями — у requirements-students.txt на сторінці лабораторних (<https://imd-course-kpi.vercel.app/labs/requirements-students.txt>), зокрема torch 2.10.0, torchxrayvision 1.4.0, grad-cam 1.5.7 і для додаткового треку ultralytics 8.4.115 (ліцензія AGPL-3.0). Обчислення — лише на CPU. Основний шлях виконується командою *Restart & Run All* **не довше 30 хвилин**: навчання класифікатора з 5 зернами — не довше 20 хв, карти й метрики на 123 знімках — не довше 10 хв. Додатковий трек — одне навчання детектора не довше 45 хв; розкид за зернами для нього не оцінюється, і це треба вказати у звіті як обмеження. Межі перевірено заміром еталонного розв'язку на Apple M1 Max (8 потоків, жовтень 2026): навіть помножений на 2,5 (процесор типового ноутбука у 2–3 рази повільніший), його час у них укладається.

Дані завантажуються без облікового запису:

- набори Montgomery (138 знімків: 80 норм і 58 із туберкульозом) і Shenzhen (662 знімки: 326 і 336), сторінка наборів — <https://data.lhncbc.nlm.nih.gov/public/Tuberculosis-Chest-X-ray-Datasets/index.html>. Адреси тек без index.html віддають помилку 403, тож файли завантажують поштучно за прямими адресами, наприклад https://data.lhncbc.nlm.nih.gov/public/Tuberculosis-Chest-X-ray-Datasets/Montgomery-County-CXR-Set/MontgomerySet/CXR_png/MCUCXR_0001_0.png і https://data.lhncbc.nlm.nih.gov/public/Tuberculosis-Chest-X-ray-Datasets/Shenzhen-Hospital-CXR-Set/CXR_png/CHNCXR_0001_0.png; переліки імен — у файлах index.html тек CXR_png, клінічні записи — однойменні .txt у теках ClinicalReadings поруч. 800 знімків займають 4,38 ГБ; поштучно — від 4 до 18 хв залежно від навантаження сервера (заміри 04–05.10.2026). Ti самі набори є архівами <https://openi.nlm.nih.gov/imgs/collections/NLM-MontgomeryCXRSet.zip> (617 МБ) і https://openi.nlm.nih.gov/imgs/collections/ChinaSet_AllFiles.zip (3,77 ГБ), але цей сервер віддає 0,5–0,75 МБ/с: Montgomery — 14–20 хв, Shenzhen — 1,5–2 год;
- копії зі стороною 256 px будує скрипт курсу https://imd-course-kpi.vercel.app/labs/make_cxr256.py: знімки кладуть у теки ПАПКА/data/nlm/Montgomery/CXR_png і ПАПКА/data/nlm/Shenzhen/CXR_png і запускають python make_cxr256.py --root ПАПКА; копії з'являються в ПАПКА/data/nlm/cxr256/ разом із таблицею розмірів sizes.csv. 800

копій займають 24 МБ і будуються менш ніж за хвилину (замір — 8 с у 8 процесорах); після цього оригінали для роботи не потрібні;

- файли рамок консенсусу (4 і 9 КБ): https://data.lhncbc.nlm.nih.gov/public/Tuberculosis-Chest-X-ray-Datasets/Montgomery-County-CXR-Set/MontgomerySet/montgomery_consensus_roi.csv і https://data.lhncbc.nlm.nih.gov/public/Tuberculosis-Chest-X-ray-Datasets/Shenzhen-Hospital-CXR-Set/shenzhen_consensus_roi.csv;
- ваги TorchXRayVision densenet121-res224-all (28,4 МБ) або DenseNet-121 ImageNet (32,3 МБ) — автоматично при першому створенні моделі;
- додатковий трек: набір TBX11K (CC BY 4.0), архів TBX11K.zip 3,31 ГБ з Google Drive (посилання — у репозиторії <https://github.com/yun-liu/Tuberculosis>); знімки 512×512 px. Рамки туберкульозу є для 799 знімків власної частини trainval набору (теку imgs/tb, 230 МБ, і анотації annotations/json/TBX11K_{train,val}_only_tb.json); увесь архів завантажився за 2,5 хв (22,9 МБ/с, жовтень 2026); сервер підтримує HTTP-запити діапазону, тож потрібні теки можна вилучити з архіву й без завантаження цілого (231 МБ за 27 с). Якщо Google Drive відмовляє через перевищення квоти завантажень, запит повторюють пізніше. У теці imgs/extra лежать знімки ще чотирьох відкритих наборів туберкульозу, серед них Montgomery і Shenzhen, і списки all_* їх включають;
- ваги YOLOv8n, навчені на COCO (6,5 МБ, <https://github.com/ultralytics/assets/releases/download/v8.4.0/yolov8n.pt>).

Після `import ultralytics` бібліотека PyTorch без заданої змінної середовища `OMP_NUM_THREADS` працює в один потік: змінну задають до імпорту або викликають `torch.set_num_threads(...)` після.

Порядок виконання

1. **[A]** Відкладіть усі 123 знімки з рамками консенсусу і на решті 677 знімках навчіть класифікатор туберкульозу за протоколом вище з 5 зернами. Наведіть склад train і validation за джерелом і класом та валідаційну AUC кожного зерна.
2. **[A]** Для всіх 123 відкладених знімків і кожного зерна побудуйте теплові карти двома методами, що дають різні карти, і вкажіть роздільність кожної карти в пікселях копії 256 px.
3. **[B]** Перетворіть карти на рамки (поріг і зв'язні компоненти) і для порогів IoU 0,1, 0,3 і 0,5 наведіть влучність і повноту на рівні об'єктів, а також частку знімків, де максимум карти влучив у рамку еталону. Ті самі метрики порахуйте для апіорної карти.
4. **[B]** Побудуйте криву «частка знайдених рамок — середня кількість хибнопозитивних рамок на знімок» при зміні порогу карти для обох методів і апіорної карти.
5. **[C]** Розберіть 20 найупевненіших хибнопозитивних рамок за анатомічною локалізацією та ймовірною причиною. Наведіть таблицю й приклади, частку хибнопозитивних рамок поза легенями і їх розподіл між Montgomery і Shenzhen.
6. **[разом]** Порівняйте два методи карт на тих самих знімках, з урахуванням розкиду за зернами і різниці між джерелами, і сформулюйте, коли карта вводиться в оману. Перша комірка ноутбука — хто з учасників за які комірки відповідав; ноутбук виконується від початку до кінця без ручних правок.
7. **[додатковий трек]** Навчіть детектор рамок туберкульозу на знімках TBX11K у межах бюджету, переконавшись, що жоден знімок оцінювальної вибірки не потрапив у навчання. Порівняйте його метрики рівня об'єкта на тих самих 123 знімках з метриками теплових карт.

Контрольні запитання

1. Чому знімки з рамками відкладено повністю, разом із мітками класу? Що змінилося б в оцінці локалізації, якби класифікатор бачив ці знімки?
2. Чому для класифікатора з глобальним усередненням і лінійною головою CAM і Grad-CAM останнього шару дають ту саму карту? Що треба змінити, щоб другий метод давав іншу інформацію?
3. Як роздільність карти обмежує IoU з малою рамкою? Порахуйте найбільший IoU клітинки 32×32 px з рамкою 16×16 px.
4. Чим гра у вказування відрізняється від IoU-метрик? Чому для неї потрібен допуск?
5. Навіщо потрібна апіорна карта? Що означає, якщо карта класифікатора влучає не частіше за неї?
6. Що відкладено по осях кривої FROC і чим вона відрізняється від ROC-кривої? Чому «хибно-позитивні на знімок» на 123 знімках з туберкульозом менше, ніж були б на скринінгу?
7. Порівняйте склад навчальних даних класифікатора за джерелом і класом зі складом відкладених знімків. Як цей склад пояснює різницю метрик локалізації між Montgomery і Shenzhen?
8. Чому метрики детектора, навченого на TBX11K, на знімках NLM не можна порівнювати з його метриками на валідації TBX11K? Що станеться, якщо навчати детектор за списками all_*?

Література

- [1] Jaeger S. et al. Two public chest X-ray datasets for computer-aided screening of pulmonary diseases. *Quantitative Imaging in Medicine and Surgery*, 2014, 4(6), 475–477. doi:10.3978/j.issn.2223-4292.2014.11.20. Умови використання наборів Montgomery і Shenzhen та файлів рамок консенсусу: посилання на цю статтю й U.S. National Library of Medicine; набори не поширюються за межі навчальної групи, похідні копії не публікуються.
- [2] Zhou B. et al. Learning Deep Features for Discriminative Localization. *CVPR*, 2016. doi:10.1109/CVPR.2016.319.
- [3] Selvaraju R. R. et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. *ICCV*, 2017. doi:10.1109/ICCV.2017.74.
- [4] Zeiler M. D., Fergus R. Visualizing and Understanding Convolutional Networks. *ECCV*, 2014. doi:10.1007/978-3-319-10590-1_53.
- [5] Zhang J. et al. Top-Down Neural Attention by Excitation Backprop. *International Journal of Computer Vision*, 2018, 126, 1084–1102. doi:10.1007/s11263-017-1059-x.
- [6] Wang X. et al. ChestX-ray8: Hospital-Scale Chest X-Ray Database and Benchmarks on Weakly-Supervised Classification and Localization of Common Thorax Diseases. *CVPR*, 2017. doi:10.1109/CVPR.2017.369.
- [7] Everingham M. et al. The PASCAL Visual Object Classes (VOC) Challenge. *International Journal of Computer Vision*, 2010, 88, 303–338. doi:10.1007/s11263-009-0275-4.
- [8] Cohen J. P. et al. TorchXRyVision: A library of chest X-ray datasets and models. *MIDL*, PMLR 172, 2022. <https://proceedings.mlr.press/v172/cohen22a.html>. Ліцензія коду — Apache-2.0.

- [9] Liu Y. et al. Rethinking Computer-Aided Tuberculosis Diagnosis. *CVPR*, 2020. doi:10.1109/CVPR42600.2020.00272. Умови використання набору TBX11K: CC BY 4.0 (сторінка набору <https://mmcheng.net/tb/>); код репозиторію має окрему ліцензію.
- [10] Jocher G., Qiu J., Chaurasia A. Ultralytics YOLO, версія 8. <https://github.com/ultralytics/ultralytics>. Ліцензія — AGPL-3.0.