

Лабораторна робота №4.

Сегментація медичних зображень за допомогою U-Net/nnU-Net-подібних моделей

5 жовтня 2026 р.

Мета

Навчитися будувати й чесно оцінювати модель сегментації медичних зображень: підготувати еталонні маски з двох наборів із різними правилами розмітки, поділити дані на рівні пацієнта, навчити 2D U-Net з різними функціями втрат і виміряти якість метриками перекриття (Dice, IoU) і межі (HD95 у міліметрах) окремо для кожного джерела, з розкидом за зернами. Друга мета — перенести задачу в 3D: навчити 3D U-Net на MPT гіпокампа в межах бюджету процесора і порівняти власну конфігурацію з тією, яку для того самого набору автоматично планує nnU-Net. Третя — навчитися аналізувати помилки сегментації за найгіршими випадками, а не лише за середнім.

Склад бригади і розподіл ролей

Роботу виконує бригада з трьох осіб. Кожен учасник відповідає за свою частину, має власний вимірюваний результат і захищає його окремо. Аналіз найгірших випадків бригада робить разом.

- **Учасник А — 2D-модель і функції втрат.** Готує знімки й маски двох наборів у спільній сітці, робить поділ на рівні пацієнта, навчає 2D U-Net з трьома функціями втрат по п'ять зерен і вибирає епоху на validation.
- **Учасник В — постобробка й метрики.** Рахує Dice, IoU і HD95 у міліметрах окремо для кожного набору, зводить середнє й розкид за зернами, застосовує постобробку й показує, що вона змінює.
- **Учасник С — 3D і конфігурація nnU-Net.** Ділить тривимірний набір за людьми, навчає 3D U-Net, рахує метрики для кожного класу, запускає планувальник nnU-Net і порівнює його план із власною конфігурацією.

Теоретичні відомості

Сегментація (англ. semantic segmentation) — задача віднести кожен піксель (воксель) зображення до одного з класів: легеня чи фон, передня чи задня частина гіпокампа чи фон. Маска потрібна там, де клінічне число залежить від меж: об'єм органа чи ураження, площа легеневих полів, область для подальшого аналізу. Тому її похибку звітують у тих самих одиницях, що й клінічне число, — у міліметрах.

U-Net (Ronneberger et al., 2015) складається з кодера, який зменшує роздільність і збільшує кількість каналів, і декодера, який відновлює роздільність до вихідної. **Skip-з'єднання** (англ. skip

connection) передають карти ознак кодера на тому самому рівні в декодер, тож декодер має і контекст глибоких шарів, і точну локалізацію перших. **3D U-Net** (Çiçek et al., 2016) замінює двовимірні згортки, пулінг і транспоновані згортки тривимірними; ціна — пам'ять, що росте пропорційно кількості вокселів входу, тому на практиці навчаються на **патчах** — фрагментах об'єму.

nnU-Net (Isensee et al., 2021) налаштовує конвеєр сегментації автоматично. Спершу він рахує **відбиток даних** (англ. dataset fingerprint): розподіл кроків вокселя, медіанну форму, статистику інтенсивностей. Далі одні параметри фіксовані (шаблон U-Net, функція втрат, аугментації, розклад навчання), інші виводяться правилами з відбитка (цільовий спейсинг, розмір патча, батч, кількість рівнів мережі, нормалізація), а вибір конфігурації (2D, 3D, каскад) і постобробки робиться емпірично на крос-валідації. Планування — відбиток і правила — не потребує ні GPU, ні навчання.

Функції втрат. Нехай $p_i \in (0, 1)$ — імовірність класу «легеня» для пікселя i (сигмоїда виходу мережі), $g_i \in \{0, 1\}$ — еталон, N — кількість пікселів, ε — мала стала, що не дає ділити на нуль. Бінарна крос-ентропія (англ. binary cross-entropy, BCE) і м'яка Dice-втрати (Milletari et al., 2016):

$$L_{\text{BCE}} = -\frac{1}{N} \sum_i [g_i \ln p_i + (1 - g_i) \ln(1 - p_i)], \quad L_{\text{Dice}} = 1 - \frac{2 \sum_i p_i g_i + \varepsilon}{\sum_i p_i + \sum_i g_i + \varepsilon}. \quad (1)$$

BCE трактує кожен піксель як окрему класифікацію, і великий фон дає більшість її внеску; Dice-втрата дивиться на всю структуру разом і від кількості фону не залежить. Поєднання $L_{\text{BCE}} + L_{\text{Dice}}$ бере стабільний градієнт першої і нечутливість до дисбалансу другої.

Метрики. Для бінарних масок прогнозу A і еталона B : коефіцієнт Дайса $\text{Dice} = 2|A \cap B|/(|A| + |B|)$ і індекс Жаккара $\text{IoU} = |A \cap B|/|A \cup B|$ міряють перекриття. Відстань Гаусдорфа — найбільша відстань від точки межі однієї маски до найближчої точки межі іншої; **HD95** замість максимуму бере 95-й перцентиль цих відстаней в обидва боки і рахується в міліметрах з урахуванням розміру пікселя. Перекриття і межа міряють різне: острівця далеко від легені майже не змінює Dice, але різко збільшує HD95, тому метрики двох сімейств звітують разом (Maier-Hein et al., 2024). Для сегментації звітують розподіл по знімках — медіану, квартилі, найгірші випадки, — а не лише середнє.

Постобробка (англ. post-processing) виправляє дефекти маски, використовуючи знання про об'єкт: легень дві, кожна суцільна. Правило «лишити дві найбільші зв'язні компоненти» прибирає острівці поза легенями, заповнення дірок прибирає фон усередині маски. Обидва правила спираються на припущення, яке на чужих даних може не виконуватися, тому рішення застосовувати постобробку ухвалюють на validation.

Дані 2D. Набір SCR (van Ginneken et al., 2006) — ручна розмітка легень, серця й ключиць для 247 рентгенограм бази JSRT (Shiraishi et al., 2000; 2048×2048 , піксель 0,175 мм). Знімки JSRT — копії 256×256 з набору miniJSRT (Gender01.zip, імена файлів — ідентифікатори JSRT); архів jpg.zip набору SCR для навчання не годиться: на його знімках уже намальовано контури розмітки. Архів масок SCR masks.zip містить лише праву легеню пацієнта; контури обох легень є в points.zip — координати точок у сітці 1024×1024 , маску отримують заливкою полігонів. Один знімок JSRT — один пацієнт. Набір Montgomery (Jaeger et al., 2014) — 138 рентгенограм (4020×4892 або 4892×4020 , піксель 0,0875 мм) з ручними масками кожної легені (Candemir et al., 2014): файл leftMask — права легеня пацієнта, rightMask — ліва. Частина легені за серцем у масках Montgomery не включено. У файлах ClinicalReadings трьох знімків є примітка «same pt as»: 138 знімків належать 135 пацієнтам. Правила розмітки двох наборів різні, тож метрики рахують окремо для кожного.

Дані 3D. Задача Task04 Medical Segmentation Decathlon (Antonelli et al., 2022) — передня (мітка 1) і задня (мітка 2) частини гіпокампа на MPT T1, воксель 1 мм. Файли — кропи навколо лівого або правого гіпокампа, а не цілі MPT; файли hippocampus_(2k-1) і hippocampus_(2k) — два кропи однієї MPT, тобто однієї людини (у пари збігається шкала інтенсивностей). Мітки є лише для imagesTr; в архіві поряд лежать службові файли macOS ._*_ з тим самим розширенням .nii.gz, що й томи.

Корисні посилання для ознайомлення:

- [MONAI: Network architectures](#) — класи UNet для 2D і 3D;
- [MONAI: Loss functions](#) — DiceLoss, DiceCELoss;
- [MONAI: Metrics](#) — compute_dice, compute_hausdorff_distance (ключ percentile);
- [nnU-Net: setting up paths, dataset format і explanation of plans files](#) — змінні середовища, формат набору і зміст файлу плану;
- [Metrics Reloaded](#) (Maier-Hein et al., 2024) — як вибрати метрики сегментації під задачу;
- [Medical Segmentation Decathlon](#) — опис задач і формату.

Середовище

Python 3.12; усі пакети з версіями — у requirements-students.txt на сторінці лабораторних (зокрема nnunetv2 2.6.4): <https://kudgey.github.io/imd-course/labs/requirements-students.txt>. Встановлення в чистому середовищі перевірено, конфліктів версій немає. Обчислення — лише на CPU. Обчислювальний бюджет — верхні межі, перевірені заміром на CPU з запасом:

- 2D: 3 функції втрат $\times$ 5 зерен = 15 навчань U-Net на знімках 256×256 , до 20 епох, **не довше 5 хв кожне** — разом до 75 хв;
- 3D: одне навчання 3D U-Net **не довше 25 хв**; розкид за зернами для 3D не оцінюється, і в звіті це вказується як обмеження;
- планування nnU-Net (конвертація набору, відбиток і план, без препроцесингу й навчання) — **до 5 хв**;
- метрики, постобробка й аналіз помилок — до 10 хв.

Весь ноутбук виконується командою *Restart & Run All* **не довше 2 год**. Якщо навчання не вкладається в бюджет, зменшують мережу або кількість епох, а не кількість зерен.

Дані завантажуються без облікового запису (час — заміряний на одному з'єднанні, у вас може бути іншим):

- знімки JSRT 256×256 , miniJSRT Gender01.zip (5,9 МБ, близько 11 с):
<http://imgcom.jsrt.or.jp/imgcom/wp-content/uploads/2018/11/Gender01.zip>
- контури SCR points.zip (0,46 МБ, менше 1 с), Zenodo, [doi:10.5281/zenodo.7056076](https://doi.org/10.5281/zenodo.7056076):
<https://zenodo.org/records/7056076/files/points.zip>
- Montgomery: знімки CXR_png (138 PNG, 614 МБ), маски ManualMask (2 $\times$ 138 PNG, 4,4 МБ) і ClinicalReadings (138 TXT) — поштучно із сервера NLM. Перелік файлів кожної теки — у її index.html; адреса файлу має вигляд .../MontgomerySet/CXR_png/MCUCXR_0001_0.png, маски — .../MontgomerySet/ManualMask/leftMask/MCUCXR_0001_0.png і так само для теки rightMask, висновки — .../MontgomerySet/ClinicalReadings/MCUCXR_0001_0.txt. Заміри 04–05.10.2026: від ≈ 4 до ≈ 20 МБ/с послідовно, тобто від $\approx 0,5$ до $\approx 2,5$ хв на знімки. Той самий набір є архівом NLM-MontgomeryCXSet.zip (617 МБ; 0,5–0,75 МБ/с, тобто ≈ 14 –20 хв):
<https://data.lhncbc.nlm.nih.gov/public/Tuberculosis-Chest-X-ray-Datasets/index.html>
https://data.lhncbc.nlm.nih.gov/public/Tuberculosis-Chest-X-ray-Datasets/Montgomery-County-CXR-Set/MontgomerySet/CXR_png/MCUCXR_0001_0.png
<https://openi.nlm.nih.gov/imgs/collections/NLM-MontgomeryCXSet.zip>

- копії знімків зі стороною 256 px за довшою стороною будує скрипт курсу `make_cxr256.py`: команда `python make_cxr256.py --root ПАПКА` читає теки `ПАПКА/data/nlm/Montgomery/CXR_png/` і `ПАПКА/data/nlm/Shenzhen/CXR_png/` і записує копії в `ПАПКА/data/nlm/cxr256/<набір>/` разом із таблицею `sizes.csv` (розміри оригіналу й копії); маски зменшують до розміру копії самостійно. Якщо копії вже є, повторно завантажувати знімки не потрібно: https://kudgey.github.io/imd-course/labs/make_cxr256.py
- MSD Task04_Hippocampus (28,4 МБ, близько 13 с): https://msd-for-monai.s3-us-west-2.amazonaws.com/Task04_Hippocampus.tar

Порядок виконання

1. **[A]** Підготуйте знімки й маски обох легень JSRT (за контурами SCR) і Montgomery (ліва й права легені разом) у спільній сітці 256×256 з відомим розміром пікселя в міліметрах для кожного набору. Поділіть кожен набір 70/15/15 на рівні пацієнта; наведіть кількість пацієнтів і знімків у кожній частині.
2. **[A]** Навчіть 2D U-Net на об'єднаній навчальній частині з трьома функціями втрат — BCE, Dice, BCE+Dice, — по 5 зерен на кожному, вибираючи епоху на validation. Наведіть криві Dice на validation за епохами і час одного навчання.
3. **[B]** Для кожної функції втрат наведіть Dice, IoU і HD95 (мм) на test окремо для JSRT і Montgomery: середнє й розкид за зернами, медіану і найгірший знімок.
4. **[B]** Застосуйте постобробку: дві найбільші зв'язні компоненти і заповнення дірок. Покажіть, як змінилися метрики, особливо HD95, на validation і на test, і на скількох знімках постобробка змінила кількість компонент.
5. **[C]** Поділіть `imagesTr` набору Task04 за людьми 70/15/15 і перевірте, що файли однієї людини не потрапили в різні частини. Навчіть 3D U-Net у межах бюджету й наведіть на test Dice і HD95 для кожного з двох класів.
6. **[C]** Запустіть автоматичне планування nnU-Net для Task04 (лише відбиток і план, без навчання). Порівняйте в таблиці вибрані ним спейсинг, розмір патча, батч, нормалізацію і топологію мережі (кількість рівнів, каналів, ядра, кроки) з вашою 3D-конфігурацією; поясніть кожну розбіжність.
7. **[разом]** Покажіть 10 найгірших знімків test за HD95 (2D) з накладеними контурами прогнозу й еталона. Для кожного — набір, гіпотеза причини і чи виправляє помилку постобробка. Перша комірка ноутбука — хто з учасників за які комірки відповідав; ноутбук виконується від початку до кінця без ручних правок.

Контрольні запитання

1. Навіщо U-Net skip-з'єднання? Що втратить декодер без них?
2. Чим BCE відрізняється від Dice-втрати за поведінкою на сильно незбалансованих класах? Чому їх поєднують?
3. Чому Dice і HD95 можуть суперечити одне одному? Наведіть приклад маски з високим Dice і великим HD95.
4. Чому HD95 рахують у міліметрах, а не в пікселях? Що станеться з порівнянням двох наборів, якщо забути про різний розмір пікселя?

5. Чому поділ Task04 за файлами, а не за людьми, завищує оцінку? Як це перевірити на даних?
6. На якому припущенні тримається постобробка «дві найбільші компоненти»? Коли вона погіршує результат?
7. Які параметри nnU-Net фіксує, які виводить правилами з відбитка даних, а які вибирає емпірично? Чому повне навчання nnU-Net на CPU непрактичне?
8. Чому метрики JSRT і Montgomery треба звітувати окремо, навіть якщо модель навчено на обох?

Література

- [1] Ronneberger O., Fischer P., Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation. *MICCAI 2015*, Lecture Notes in Computer Science, 234–241. doi:10.1007/978-3-319-24574-4_28.
- [2] Çiçek Ö. et al. 3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation. *MICCAI 2016*, Lecture Notes in Computer Science, 424–432. doi:10.1007/978-3-319-46723-8_49.
- [3] Milletari F., Navab N., Ahmadi S.-A. V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation. *3DV 2016*, 565–571. doi:10.1109/3DV.2016.79.
- [4] Isensee F. et al. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. *Nature Methods*, 2021, 18, 203–211. doi:10.1038/s41592-020-01008-z. Програмний код: <https://github.com/MIC-DKFZ/nnUNet>, ліцензія Apache 2.0.
- [5] Maier-Hein L. et al. Metrics reloaded: recommendations for image analysis validation. *Nature Methods*, 2024, 21, 195–212. doi:10.1038/s41592-023-02151-z.
- [6] van Ginneken B., Stegmann M. B., Loog M. Segmentation of anatomical structures in chest radiographs using supervised methods: a comparative study on a public database. *Medical Image Analysis*, 2006, 10(1), 19–40. doi:10.1016/j.media.2005.02.002. Набір SCR: doi:10.5281/zenodo.7056076. Умови використання: CC BY 4.0, з посиланням на цю статтю.
- [7] Shiraishi J. et al. Development of a digital image database for chest radiographs with and without a lung nodule. *American Journal of Roentgenology*, 2000, 174(1), 71–74. doi:10.2214/ajr.174.1.1740071. Набір miniJSRT: <http://imgcom.jsrt.or.jp/minijsrtdb/>. Умови використання: явної відкритої ліцензії немає; для навчання й досліджень, не для комерційних порівнянь, з посиланням на цю статтю; знімки не поширюються далі.
- [8] Jaeger S. et al. Two public chest X-ray datasets for computer-aided screening of pulmonary diseases. *Quantitative Imaging in Medicine and Surgery*, 2014, 4(6), 475–477. doi:10.3978/j.issn.2223-4292.2014.11.20. Умови використання набору Montgomery: посилання на цю статтю і на U.S. National Library of Medicine; набір не поширюють за межі своєї групи, нові запити переадресовують NLM.
- [9] Candemir S. et al. Lung segmentation in chest radiographs using anatomical atlases with nonrigid registration. *IEEE Transactions on Medical Imaging*, 2014, 33(2), 577–590. doi:10.1109/TMI.2013.2290491. Опис масок легень Montgomery.
- [10] Antonelli M. et al. The Medical Segmentation Decathlon. *Nature Communications*, 2022, 13, 4128. doi:10.1038/s41467-022-30695-9. Умови використання набору: CC BY-SA 4.0; похідні дані поширюються на тих самих умовах.