

Лабораторна робота №5.

Навчання в умовах обмеженої розмітки та перевірка узагальнення

5 жовтня 2026 р.

Мета

Навчитися чесно вимірювати, скільки дає кожна мітка і кожен спосіб її зекономити: побудувати криву «якість від частки міток» з розкидом за зернами, порівняти з навчанням лише на мічених знімках напівкерований метод і перенесення навчання з різних початкових ваг, оцінивши приріст із довірчим інтервалом. Друга мета — перевірити узагальнення: виміряти, як класифікатор туберкульозу, навчений на знімках однієї лікарні, працює на знімках іншої, чому оцінка в межах домену завищує результат, як мала навчальна вибірка збільшує розкид і що дає один простий спосіб зменшити зсув домену. Третя — навчитися відрізняти висновки, стійкі до вибору зерна, від випадкових.

Склад бригади і розподіл ролей

Роботу виконує бригада з трьох осіб. Кожен учасник відповідає за свою частину, має власний вимірюваний результат і захищає його окремо. Підсумкову таблицю стійкості висновків бригада складає разом.

- **Учасник А — криві за часткою міток.** Відбирає мічені підмножини, навчає мережу з нуля на кожній частці для п'яти зерен, будує криву з розкидом і звітує кількість мічених знімків у кожній точці.
- **Учасник В — напівкероване навчання і початкові ваги.** Застосовує псевдорозмітку або метод на узгодженості передбачень на тих самих мічених підмножинах, оцінює приріст із довірчим інтервалом, порівнює три варіанти початкових ваг енкодера.
- **Учасник С — зсув домену.** Будує поділи на рівні пацієнта для двох наборів рентгенограм туберкульозу, вимірює якість у межах домену і на зовнішньому наборі в обох напрямках, застосовує й оцінює один спосіб зменшення зсуву.

Теоретичні відомості

Чому мало міток. Медичну мітку ставить лікар, і вона дорога, а нерозмічених знімків у будь-якій лікарні в рази більше. Тому практичне питання не «яка модель краща», а «скільки мічених знімків потрібно і що дають нерозмічені знімки або чужі дані». Відповідь дає **крива «якість від частки міток»** (англ. label-efficiency curve) — якість на фіксованій частині для оцінки як функція кількості мічених знімків.

Якість ранжування вимірює площа під ROC-кривою (AUC) — імовірність того, що випадковий знімок хворого отримає вищу оцінку моделі, ніж випадковий знімок здорового; 0,5 — вгадування, 1 — повне розділення. AUC від поширеності хвороби не залежить, а чутливість і специфічність залежать від вибраного порогу.

Протокол чесного експерименту (Oliver et al., 2018): validation і test фіксують на рівні пацієнта до того, як відбирати мічені знімки; мічену частину відбирають стратифіковано, і для однієї частки та одного зерна всі методи отримують ті самі мічені знімки; бюджет навчання (кількість кроків) однаковий для всіх часток і методів, ранньої зупинки за test немає; кожну точку повторюють щонайменше для п'яти зерен; у звіті — кількість мічених знімків, а не лише відсоток. **Зерно** (англ. random seed) тут визначає, які знімки потрапили в мічену частину, початкові ваги й порядок батчів.

Перенесення навчання (англ. transfer learning). Енкодер, який пройшов **попереднє навчання** (англ. pretraining) на іншій великій вибірці, перетворює знімок на вектор ознак; логістична регресія на заморожених ознаках (**лінійний зонд**, англ. linear probe) міряє, наскільки класи лінійно відокремлювані в цьому просторі. Порівнюють ваги після попереднього навчання на фотографіях (ImageNet; Deng et al., 2009), на рентгенограмах грудної клітки (бібліотека TorchXRayVision; Cohen et al., 2022) і випадкові ваги тієї самої архітектури — останні показують, скільки дає сама архітектура без попереднього навчання.

Напівкероване навчання (англ. semi-supervised learning) використовує нерозмічені знімки. **Псевдорозмітка** (англ. pseudo-labeling; Lee, 2013): модель, навчена на мічених знімках, ставить мітки нерозміченим, і знімки з упевненим прогнозом — $\max(p, 1 - p) \geq \tau$, де τ — поріг упевненості, — додаються до навчання. Небезпека — **зміщення підтвердження** (англ. confirmation bias; Arazo et al., 2020): упевнена помилка стає навчальною міткою. Методи на **узгодженості** (англ. consistency regularization), наприклад FixMatch (Sohn et al., 2020), вимагають, щоб прогноз для сильно аугментованого знімка збігався з упевненим прогнозом для слабо аугментованого. Поріг τ і силу аугментацій фіксують заздалегідь або вибирають на validation, не на test.

Довірчий інтервал для приросту. Оскільки обидва методи для кожного зерна отримують ті самі мічені знімки, різниці парні. Розкид за зернами враховує 95 % інтервал Стюдента для середньої різниці, $\bar{d} \pm t_{0,975; n-1} s_d / \sqrt{n}$, де $\bar{d}$ і s_d — середнє й стандартне відхилення різниць за n зернами; випадковість самої тестової вибірки — парний бутстреп (англ. paired bootstrap) за знімками test. Висновок «метод кращий» стійкий, коли знак різниці однаковий в усіх зернах і інтервал не містить нуля.

Зсув домену (англ. domain shift) — зміна розподілу вхідних даних між навчанням і використанням: інший апарат, протокол, популяція, поширеність. Модель, оцінена на test того самого набору, на знімках іншої лікарні буває помітно гіршою (Zech et al., 2018); тому, крім оцінки в межах домену, роблять **зовнішню оцінку** (англ. external validation) на наборі, який не брав участі ні в навчанні, ні у виборі порогу. Поріг, вибраний на validation джерела, на чужому наборі дає іншу пару «чутливість — специфічність». Два прості способи зменшити зсув: **нормалізація інтенсивностей** кожного знімка (наприклад, вирівнювання гістограми) в обох доменах і **AdaBN** (Li et al., 2018) — переоцінка статистик пакетної нормалізації (середніх і дисперсій шарів BatchNorm) енкодера на знімках цільового домену без міток.

Дані. PneumoniaMNIST із MedMNIST (Yang et al., 2023) — 5 856 дитячих рентгенограм із набору Kermany et al. (2018) з мітками «норма» і «пневмонія»; тут — версія 64×64 пікселі з офіційними частинами train 4 708, validation 524 і test 624. Ідентифікаторів пацієнтів у наборі немає: офіційні частини поділено за знімками, тож вимогу поділу на рівні пацієнта для цього набору виконати не можна, і в звіті це вказується як обмеження. Набори туберкульозу NLM (Jaeger et al., 2014): Shenzhen — 662 знімки (336 з туберкульозом), Montgomery — 138 знімків (58 з туберкульозом) від 135 пацієнтів (примітка «same pt as» у ClinicalReadings трьох знімків). Частина PNG Shenzhen палітрові, з оберненою палітрою, тож знімки читають із перетворенням у сірий режим (convert("L") у Pillow). Копії Montgomery зі стороною 256 пікселів за довшою стороною неквадратні, а копії Shenzhen майже квадратні: форма кадру і поля доповнення самі по собі видають

джерело знімка.

Корисні посилання для ознайомлення:

- [MedMNIST](#) і [репозиторій MedMNIST](#) — завантаження PneumoniaMNIST розміру 64 (size=64);
- [Документація TorchXRayVision](#) — моделі, попередньо навчені на рентгенограмах, і масштаб входу;
- [torchvision: densenet121](#) — ваги ImageNet і випадкова ініціалізація тієї самої архітектури;
- [scikit-learn: Semi-supervised learning](#) — самонавчання на псевдомітках;
- [PyTorch: BatchNorm2d](#) — накопичені статистики, параметр momentum;
- [scikit-image: exposure](#) — вирівнювання гістограми.

Середовище

Python 3.12; усі пакети з версіями — у requirements-students.txt на сторінці лабораторних (зокрема medmnist і torchxrayvision): <https://imd-course-kpi.vercel.app/labs/requirements-students.txt>. Обчислення — лише на CPU. Обчислювальний бюджет — верхні межі, перевірені заміром на CPU з запасом:

- криві: 6 часток $\times$ 5 зерен = 30 навчань малої CNN на знімках 64×64 , однакова кількість кроків, **не довше 1,5 хв кожне** — разом до 45 хв;
- напівкероване навчання: 2 частки $\times$ 5 зерен = 10 прогонів (псевдомітки для пулу й навчання з нуля) **не довше 1,5 хв кожен** — до 15 хв;
- три варіанти початкових ваг при 10 %: заморожений енкодер і лінійний зонд; ознаки для ваг ImageNet і рентгенограм рахуються один раз (**до 5 хв** на кожен варіант), для випадкових ваг — у кожному зерні; 15 прогонів **не довше 1,5 хв кожен** — разом до 33 хв;
- зсув домену: ознаки замороженого енкодера для 800 рентгенограм один раз (**до 5 хв**), 2 напрямки $\times$ 5 зерен = 10 навчань класифікатора **не довше 1 хв кожне** — разом до 15 хв;
- зменшення зсуву — до 10 хв.

Разом до 2 год; весь ноутбук виконується командою *Restart & Run All* **не довше 2,5 год**. Якщо прогін не вкладається в бюджет, зменшують мережу, роздільність або кількість кроків, а не кількість зерен.

Дані й ваги завантажуються без облікового запису (час — заміряний на одному з'єднанні, у вас може бути іншим):

- PneumoniaMNIST 64×64 (pneumoniamnist_64.npz, 20,6 МБ, близько 4 с), Zenodo, [doi:10.5281/zenodo.10519652](https://doi.org/10.5281/zenodo.10519652):
https://zenodo.org/records/10519652/files/pneumoniamnist_64.npz
- Shenzhen і Montgomery: знімки CXR_png (662 PNG, 3,77 ГБ; 138 PNG, 614 МБ) і Clinical Readings — поштучно із сервера NLM. Перелік файлів кожної теки — у її index.html; адреса файлу має вигляд .../Shenzhen-Hospital-CXR-Set/CXR_png/CHNCXR_0001_0.png і .../Montgomery-County-CXR-Set/MontgomerySet/CXR_png/MCUCXR_0001_0.png, висновки — у теках ClinicalReadings з тими самими іменами й розширенням .txt. Заміри 04–05.10.2026: від ≈ 4 до ≈ 20 МБ/с послідовно, тобто 4,38 ГБ обох наборів — від ≈ 4

до ≈ 18 хв. Ti самі набори є архівами ChinaSet_AllFiles.zip (3,77 ГБ) і NLM-Montgomery CXRSet.zip (617 МБ), але сервер архівів віддає 0,5–0,75 МБ/с: $\approx 1,5$ –2 год і ≈ 14 –20 хв:

<https://data.lhncbc.nlm.nih.gov/public/Tuberculosis-Chest-X-ray-Datasets/index.html>

https://data.lhncbc.nlm.nih.gov/public/Tuberculosis-Chest-X-ray-Datasets/Shenzhen-Hospital-CXR-Set/CXR_png/CHNCXR_0001_0.png

- копії зі стороною 256 px за довшою стороною будує скрипт курсу make_cxr256.py: команда `python make_cxr256.py --root ПАПКА` читає теки ПАПКА/data/nlm/Montgomery/CXR_png/ і ПАПКА/data/nlm/Shenzhen/CXR_png/ і записує копії в ПАПКА/data/nlm/cxr256/<набір>/ разом із таблицею sizes.csv (розміри оригіналу й копії); якщо копії вже є, повторно завантажувати знімки не потрібно:

https://imd-course-kpi.vercel.app/labs/make_cxr256.py

- ваги DenseNet-121, попередньо навчені на рентгенограмах (TorchXRayVision, назва ваг densenet121-res224-all, 28,4 МБ, близько 2 с), і ваги ImageNet для DenseNet-121 (torchvision, 32,3 МБ, близько 1 с) завантажуються бібліотеками автоматично при першому зверненні.

Порядок виконання

1. **[А]** Побудуйте криву якості на PneumoniaMNIST 64×64 для частки розмічених знімків 1, 5, 10, 25, 50 і 100 % навчальної частини: та сама мережа з нуля й та сама кількість кроків навчання для всіх часток, 5 зерен на точку. Наведіть AUC на test (середнє, розкид, мінімум і максимум) і кількість мічених знімків у кожній точці.
2. **[В]** Для 5 % і 10 % розмітки застосуйте псевдорозмітку або метод на узгодженості передбачень із тими самими міченими знімками й зернами, що в п. 1. Наведіть приріст AUC відносно навчання лише на мічених знімках з 95 % довірчим інтервалом, кількість прийнятих псевдоміток і частку правильних серед них.
3. **[В]** При 10 % розмітки порівняйте три варіанти початкових ваг однієї архітектури енкодера — випадкові, після попереднього навчання на ImageNet і після попереднього навчання на рентгенограмах, по 5 зерен — і зіставте їх із мережею з нуля з п. 1.
4. **[С]** Навчіть класифікатор туберкульозу на Shenzhen (поділ 70/15/15 на рівні пацієнта, поріг — на validation, 5 зерен поділу) і оцініть його на test Shenzhen і на всіх знімках Montgomery: AUC, чутливість і специфічність.
5. **[С]** Повторіть п. 4 у зворотному напрямі — навчання на Montgomery, оцінка на test Montgomery і на всіх знімках Shenzhen — як демонстрацію малих даних. Порівняйте розкид за зернами з прямим напрямом.
6. **[С]** Застосуйте один спосіб зменшення зсуву — нормалізацію інтенсивностей або переоцінку статистик пакетної нормалізації на знімках Montgomery без міток — і виміряйте його ефект на Montgomery для тих самих 5 поділів Shenzhen.
7. **[разом]** Зведіть усі порівняння п. 1–6 у таблицю: різниця, 95 % інтервал, у скількох зернах знак той самий. Позначте, які висновки стійкі до вибору зерна, а які ні. Перша комірка ноутбука — хто з учасників за які комірки відповідав; ноутбук виконується від початку до кінця без ручних правок.

Контрольні запитання

1. Чому для однієї частки міток усі методи мають отримувати ті самі мічені знімки? Що станеться з порівнянням, якщо кожен метод відбиратиме свої?
2. Чому бюджет навчання фіксують у кроках, а не в епохах? Що станеться з кривою, якщо навчати фіксовану кількість епох?
3. Що таке зміщення підтвердження в псевдорозмітці? Як поріг упевненості впливає на кількість і якість псевдоміток?
4. Чим інтервал за зернами відрізняється від бутстреп-інтервалу за знімками test? Яку невизначеність враховує кожен?
5. Навіщо серед варіантів початкових ваг потрібні випадкові ваги тієї самої архітектури? Що саме вимірює порівняння з ними?
6. Від чого залежить, чи збережеться AUC на зовнішньому наборі? Чому поріг, вибраний на validation джерела, на іншому наборі може дати іншу чутливість і специфічність?
7. Від чого залежить розкид AUC за зернами при оцінці в межах домену? Як на нього впливають розмір навчальної частини і кількість хворих і здорових у test?
8. Що змінює AdaBN в енкодері і чому для неї не потрібні мітки цільового домену? Які ознаки джерела (наприклад, форму кадру) вона не прибирає?

Література

- [1] Yang J. et al. MedMNIST v2 — A large-scale lightweight benchmark for 2D and 3D biomedical image classification. *Scientific Data*, 2023, 10, 41. [doi:10.1038/s41597-022-01721-8](https://doi.org/10.1038/s41597-022-01721-8). Умови використання PneumoniaMNIST: CC BY 4.0, з посиланням на цю статтю і на [2].
- [2] Kermany D. S. et al. Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning. *Cell*, 2018, 172(5), 1122–1131.e9. [doi:10.1016/j.cell.2018.02.010](https://doi.org/10.1016/j.cell.2018.02.010).
- [3] Jaeger S. et al. Two public chest X-ray datasets for computer-aided screening of pulmonary diseases. *Quantitative Imaging in Medicine and Surgery*, 2014, 4(6), 475–477. [doi:10.3978/j.issn.2223-4292.2014.11.20](https://doi.org/10.3978/j.issn.2223-4292.2014.11.20). Умови використання наборів Shenzhen і Montgomery: посилання на цю статтю і на U.S. National Library of Medicine; набори не поширюють за межі своєї групи, нові запити переадресовують NLM.
- [4] Cohen J. P. et al. TorchXRyVision: A library of chest X-ray datasets and models. *Medical Imaging with Deep Learning (MIDL)*, 2022. [arXiv:2111.00595](https://arxiv.org/abs/2111.00595). Програмний код і ваги: <https://github.com/mlmed/torchxrayvision>, ліцензія Apache 2.0.
- [5] Huang G. et al. Densely Connected Convolutional Networks. *CVPR 2017*, 2261–2269. [doi:10.1109/CVPR.2017.243](https://doi.org/10.1109/CVPR.2017.243).
- [6] Deng J. et al. ImageNet: A large-scale hierarchical image database. *CVPR 2009*, 248–255. [doi:10.1109/CVPR.2009.5206848](https://doi.org/10.1109/CVPR.2009.5206848).
- [7] Oliver A. et al. Realistic Evaluation of Deep Semi-Supervised Learning Algorithms. *NeurIPS 2018*. [arXiv:1804.09170](https://arxiv.org/abs/1804.09170).
- [8] Lee D.-H. Pseudo-Label: The Simple and Efficient Semi-Supervised Learning Method for Deep Neural Networks. *ICML 2013 Workshop on Challenges in Representation Learning*, 2013.

- [9] Arazo E. et al. Pseudo-Labeling and Confirmation Bias in Deep Semi-Supervised Learning. *IJCNN 2020*, 1–8. doi:[10.1109/IJCNN48605.2020.9207304](https://doi.org/10.1109/IJCNN48605.2020.9207304).
- [10] Sohn K. et al. FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence. *NeurIPS 2020*. arXiv:[2001.07685](https://arxiv.org/abs/2001.07685).
- [11] Li Y. et al. Adaptive Batch Normalization for practical domain adaptation. *Pattern Recognition*, 2018, 80, 109–117. doi:[10.1016/j.patcog.2018.03.005](https://doi.org/10.1016/j.patcog.2018.03.005).
- [12] Zech J. R. et al. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study. *PLOS Medicine*, 2018, 15(11), e1002683. doi:[10.1371/journal.pmed.1002683](https://doi.org/10.1371/journal.pmed.1002683).
- [13] Cheplygina V., de Bruijne M., Pluim J. P. W. Not-so-supervised: A survey of semi-supervised, multi-instance, and transfer learning in medical image analysis. *Medical Image Analysis*, 2019, 54, 280–296. doi:[10.1016/j.media.2019.03.009](https://doi.org/10.1016/j.media.2019.03.009).